ESCOLA
SUPERIOR
DE TECNOLOGIA
E GESTÃO
POLITÉCNICO
DO PORTO

MESTRADO
ENGENHARIA INFORMÁTICA – **TECNOLOGIAS ESCALÁVEIS PARA ANÁLISE DE DADOS**

Otimização e Eficiência de Energia (MIBEL)

8220800 - Avelino Almeida
8030078 - Fernando Lucas
8250639 – Rui Guerra

Março / 2026

Conteúdo

Acrónimos **iii**

1 Contexto e Motivação **1**
1.1 Visão Geral (Cenário) 1
1.2 Conjuntos de Dados Selecionados 2
1.2.1 Consumo Total Nacional da Rede 2
1.2.2 Preços *Spot* do MIBEL (Mercado Diário) 3
1.2.3 Meteorologia Horária 3
1.2.4 Produção Solar e Autoconsumo Doméstico 4
1.3 Dicionário de Dados 4
1.3.1 Consumo Total Nacional 5
1.3.2 Produção Total Nacional 5
1.3.3 Preços *Spot* MIBEL (Mercado Diário) 5
1.3.4 Meteorologia Horária 6
1.3.5 Energia Injetada por UPAC 6
1.3.6 Instalações Fotovoltaicas de Autoconsumo UPAC 6
1.4 Integração e Relação entre Datasets 7
1.5 Trabalho Futuro 7
1.5.1 Fontes de Dados Complementares 7

Lista de Tabelas

1.1 Visão geral dos datasets selecionados. 2
1.2 Dicionário de dados — `consumo-total-nacional.csv`. 5
1.3 Dicionário de dados — `energia-produzida-total-nacional.csv`. 5
1.4 Dicionário de dados — `DAY-AH_1.CSV`. 6
1.5 Dicionário de dados — `open-meteo-38.70N9.20W64m.csv`. 6
1.6 Dicionário de dados — `energia_injectada_upac.csv`. 6
1.7 Dicionário de dados — `8-unidades-de-producao...csv`. 7
1.8 Fontes de dados complementares recomendadas para trabalho futuro. . . . 8

Acrónimos

MIBEL Mercado Ibérico de Electricidade

OMIE Operador del Mercado Ibérico de Energía

REN Redes Energéticas Nacionais

UPAC Unidade de Produção para Autoconsumo

UTC Coordinated Universal Time

Capítulo 1

Contexto e Motivação

O mercado elétrico grossista MIBEL (*Mercado Ibérico de Electricidade*) é caracterizado por elevada volatilidade intradiária nos preços de energia, resultante da combinação de uma procura relativamente rígida com uma oferta crescentemente dominada por fontes renováveis intermitentes. Esta volatilidade cria desafios operacionais e financeiros significativos para os agentes de mercado, nomeadamente para os comercializadores de energia a retalho, que devem equilibrar o risco de comprar em excesso (capital imobilizado) com o risco de comprar em défice (recurso ao mercado de ajuste a preços penalizadores).

Neste projeto, iremos construir uma plataforma de dados do tipo *lakehouse* desenhada para suportar estes processos de decisão, integrando fluxos de dados reais de rede, mercado, produção distribuída e meteorologia. O presente capítulo detalha o contexto de negócio e fundamenta a seleção dos conjuntos de dados que alimentarão a arquitetura.

Adicionalmente, com o intuito de testar a escalabilidade e a capacidade de processamento granular da plataforma, o âmbito do projeto foi expandido (por sugestão do docente) para abranger o contexto doméstico de autoconsumo fotovoltaico. Neste cenário, agentes individuais (*prosumers*) procuram otimizar a sua operação e a venda de excedentes à rede, necessitando de cruzar a variabilidade local das condições meteorológicas com os sinais de preço do MIBEL

1.1 Visão Geral (Cenário)

Consideramos o cenário hipotético de uma empresa comercializadora, designada **EnerFlow, Lda.**, que opera no mercado português de eletricidade. A EnerFlow agrega uma carteira diversificada de clientes, incluindo consumidores domésticos convencionais e *prosumers* (clientes com instalações fotovoltaicas de autoconsumo, legalmente designadas UPAC).

O modelo de negócio da EnerFlow assenta em três pilares analíticos:

- Compra de energia no mercado diário MIBEL para cobrir a procura dos clientes, antecipando os picos de consumo e a injeção de produção distribuída na rede;
- Gestão da exposição financeira face à volatilidade de preços e aos desvios entre a energia previamente contratada e o consumo real, minimizando o recurso ao dispendioso mercado de ajuste;

- Prestação de um serviço de aconselhamento dinâmico a *prosumers*, recomendando as janelas horárias ideais para autoconsumo, armazenamento ou venda de excedentes à rede.

Para suportar esta operação, a plataforma cruza dados de diferentes origens. A chave temporal (*timestamp* normalizado para UTC) e a dimensão espacial (zona de mercado nacional e coordenadas geográficas da meteorologia local) formam o eixo central de integração na camada *Silver* do *Lakehouse*.

1.2 Conjuntos de Dados Selecionados

Foram selecionados seis conjuntos de dados provenientes de fontes abertas oficiais, cobrindo as quatro dimensões fundamentais do cenário descrito. A Tabela 1.1 apresenta uma visão de conjunto.

Tabela 1.1: Visão geral dos datasets selecionados.

Ficheiro	**Período**	**Granular.**	**Registos**	**Observações**
`consumo-total-nacional.csv`	2023-01/2025-02	15 min	111 085	Lacunas temporais
`DAY-AH_1.CSV`	2023-01/2026-03	Horária	27 984	1 383 preços ≤ 0
`open-meteo-(...).csv`	2024-01/2024-12	Horária	8 783	Apenas 1 ano
`energia_injectada_upac.csv`	2023-05/2024	Mensal	12 360	Grafia inconsist.
`energia-produzida-total-nacional.csv`	2023-03/2023-04	15 min	109 933	Período curto
`8-unidades-de-producao-(...).csv`	2024T2	Trimestral	146 418	Snapshot estático

Nesta secção descrevemos cada conjunto de dados, a sua origem, estrutura e relação com o cenário.

1.2.1 Consumo Total Nacional da Rede

- **Fonte**: Portal Open Data da E-REDES[1].
- **Granularidade**: Intervalos de 15 minutos por nível de tensão, agregáveis à resolução horária e ao total nacional.
- **Estrutura do ficheiro** `consumo-total-nacional.csv`:
  - `datahora` — instante temporal da medição no formato ISO 8601;
  - `dia`, `mes`, `ano`, `date`, `time` — componentes temporais redundantes exportados na origem;
  - `bt`, `mt`, `at`, `mat` — consumo por nível de tensão (kWh);
  - `total` — soma dos quatro níveis de tensão (kWh).
- **Utilização**: Caracterização da procura real de energia ao longo do tempo. Serve de base para o cálculo de desvios entre energia contratada e consumida, e como variável de entrada (*feature*) em modelos preditivos de carga.

[1] E-REDES Open Data, dataset *Consumo Total Nacional*: `https://e-redes.opendatasoft.com/`.

- **Desafios de qualidade e Tratamento**: Lacunas temporais nas séries (*timestamps* não consecutivos a 15 minutos), gestão de transições de horário de verão (DST) e validação da consistência matemática entre o campo `total` e a soma das tensões. A presença de colunas de calendário redundantes na origem justifica a aplicação estrita da arquitetura *Medallion*: a camada *Bronze* armazenará o ficheiro no seu estado bruto e imutável (*as-is*), enquanto a transição para a camada *Silver* (através do motor Trino) forçará a normalização do esquema, projetando apenas as colunas necessárias e otimizando o modelo de dados para analítica.

1.2.2 Preços *Spot* do MIBEL (Mercado Diário)

- **Fonte**: OMIE / REN DataHub[2].
- **Granularidade**: Hora × Dia para as zonas de Portugal e Espanha.
- **Estrutura do ficheiro** `DAY-AH_1.CSV`:
  - `Date` — data de entrega da energia;
  - `Hour` — hora de entrega, convenção 1–24 (em vez de 0–23);
  - `Portugal`, `Spain` — preço do mercado diário (€/MWh) por zona.
- **Utilização**: Cálculo do custo de aquisição de energia pelo comercializador e da exposição ao risco financeiro. Serve ainda para definir as janelas horárias de otimização para a venda de excedentes à rede por parte dos *prosumers*.
- **Desafios de qualidade**: A presença de 1 383 registos com preço ≤ 0 (cerca de 5% do total). Estes preços não são erros (refletem períodos reais de excesso de produção renovável), mas exigem validação explícita no contrato de dados para não quebrarem cálculos de média a jusante. A nível de estrutura, o ficheiro utiliza ponto e vírgula como separador e contém duas linhas de metadados (texto livre) antes do cabeçalho, exigindo um salto de leitura (*skip*) na ingestão para a camada *Bronze*.

1.2.3 Meteorologia Horária

- **Fonte**: API Open-Meteo[3].
- **Granularidade**: Hora × coordenadas geográficas (38,70°N / 9,20°W, altitude 64 m — Lisboa).
- **Estrutura do ficheiro** `open-meteo-38.70N9.20W64m.csv`:
  - `time` — *timestamp* UTC horário no formato ISO 8601;
  - `temperature_2m` — temperatura do ar a 2 metros (°C);
  - `cloud_cover` — nebulosidade total (%);
  - `shortwave_radiation` — radiação solar global à superfície (W/m^2);
  - `precipitation` — precipitação horária (mm).

[2] REN DataHub, secção *Electricity Market*: `https://datahub.ren.pt/en/electricity/market/`.

[3] Open-Meteo, *Historical Weather API*. Endpoint: `https://archive-api.open-meteo.com/v1/archive`.

- **Utilização**: Variáveis explicativas fundamentais para a previsão de consumo (temperatura) e de produção fotovoltaica (radiação, nebulosidade), tanto ao nível agregado nacional como em cenários domésticos.
- **Desafios de qualidade e Tratamento**: O ficheiro exportado apresenta uma estrutura atípica, incluindo metadados geográficos nas primeiras linhas antes do cabeçalho real dos dados tabulares. Esta anomalia quebra processos de ingestão automáticos (*schema-on-read*), exigindo a parametrização do salto destas linhas (*skip*) no conector de armazenamento para a camada *Bronze*. Adicionalmente, o histórico atual restringe-se ao ano de 2024, o que forçará a orquestração de tarefas complementares de extração via API para garantir o alinhamento temporal pleno (2023–2026) com as séries temporais da E-REDES e da OMIE na camada *Silver*.

1.2.4 Produção Solar e Autoconsumo Doméstico

Três ficheiros complementares caracterizam a dimensão de produção distribuída:

- **Produção agregada** (`energia-produzida-total-nacional.csv` — E-REDES/REN): produção elétrica nacional total (DGM + PRE) a 15 minutos, com colunas `datahora`, `dgm`, `pre` e `total` (kWh). O ficheiro disponível cobre apenas março–abril de 2023, o que é insuficiente para análise sazonal; é necessário ampliar o horizonte temporal.
- **Injeção UPAC mensal** (`energia\_injectada\_upac.csv` — E-REDES): energia injetada na rede por instalações UPAC, com desagregação mensal por distrito/concelho e nível de tensão (`BTN/BTE`, `MT/AT`). Permite quantificar a contribuição do autoconsumo por região.[4]
- **Inventário UPAC** (`8-unidades-de-producao-para-autoconsumo.csv` — E-REDES): inventário trimestral de instalações UPAC, com detalhe por freguesia, tecnologia, escalão de potência e número de CPE. Útil para análise de penetração fotovoltaica por zona geográfica.

Desafios de qualidade comuns: dados provisórios, eventuais lacunas e necessidade de compatibilização entre escalas (agregado nacional vs. perfis-tipo domésticos); grafia inconsistente de concelhos no ficheiro de injeção UPAC.

1.3 Dicionário de Dados

Esta secção apresenta a estrutura lógica e a semântica de cada ficheiro selecionado, bem como as anomalias detetadas na análise exploratória.

Importa clarificar a distinção entre o modelo lógico aqui detalhado e a implementação física na plataforma *Lakehouse*. Na fase de ingestão para a camada *Bronze* (armazenamento de objetos no MinIO), todos os ficheiros CSV são preservados no seu estado bruto, sendo as colunas lidas nativamente como texto simples (`VARCHAR`). Os tipos de dados documentados nas tabelas seguintes (`TIMESTAMP`, `FLOAT`, `INTEGER`) representam o esquema alvo. A transição técnica — conversão de tipos (*casting*), remoção de linhas de metadados, limpeza

[4] E-REDES Open Data: `https://e-redes.opendatasoft.com/`.

de formatos e tratamento de nulos, será executada de forma programática pelo motor Trino durante a promoção dos dados para a camada *Silver*.

1.3.1 Consumo Total Nacional

Fonte: E-REDES Open Data *Registos*: 111 085 *Período*: 2023-01-01 a 2026-03-04 *Granularidade*: 15 min

Tabela 1.2: Dicionário de dados — `consumo-total-nacional.csv`.

Campo	Tipo Alvo	Descrição	Exemplo Real	Notas de Qualidade (Silver)
`datahora`	TIMESTAMP	Instante UTC da medição (15 min)	`2023-01-01T03:00:00+00:00`	Requer tratamento de fuso horário
`dia, mes, ano`	INTEGER	Componentes de data	`01`	Descartar (redundância da origem)
`date, time`	STRING	Data e hora isoladas	`2023-01-01` / `03:00`	Descartar (redundância da origem)
`bt, mt, at, mat`	FLOAT	Consumo por tensão (kWh)	`634627.886`	Converter de texto para decimal
`total`	FLOAT	Soma de consumo global (kWh)	`1017954.255`	Validar consistência matemática

1.3.2 Produção Total Nacional

Fonte: E-REDES / REN DataHub *Registos*: 109 933 *Período*: 2023-01-01 a 2026-02-19 *Granularidade*: 15 min

Tabela 1.3: Dicionário de dados — `energia-produzida-total-nacional.csv`.

Campo	Tipo Alvo	Descrição	Exemplo Real	Notas de Qualidade (Silver)
`datahora`	TIMESTAMP	Instante UTC da medição (15 min)	`2024-03-21T11:00:00+00:00`	Requer tratamento de fuso horário
`dia, mes, ano`	INTEGER	Componentes de data	`21`	Descartar (redundância da origem)
`date, time`	STRING	Data e hora isoladas	`2024-03-21` / `11:00`	Descartar (redundância da origem)
`dgm`	FLOAT	Prod. Despacho/Gestão (kWh)	`846436.0`	Converter de texto para decimal
`pre`	FLOAT	Prod. Pequena/Renovável (kWh)	`768853.25`	Converter de texto para decimal
`total`	FLOAT	Produção total (kWh)	`1615289.25`	Converter de texto para decimal

1.3.3 Preços *Spot* MIBEL (Mercado Diário)

Fonte: OMIE / REN DataHub *Registos*: 27 984 *Período*: 2023-01-01 a 2026-03-10 *Granularidade*: Horária

Tabela 1.4: Dicionário de dados — `DAY-AH_1.CSV`.

Campo	Tipo Alvo	Descrição	Exemplo Real	Notas de Qualidade (Silver)
`Date`	DATE	Data de entrega da energia	`2023-01-01`	Omitir 2 linhas iniciais de metadados
`Hour`	INTEGER	Hora de entrega (1–24)	`1`	Normalizar para formato `00-23`
`Portugal`	FLOAT	Preço horário PT (€/MWh)	`0.00`	Validar e sinalizar valores ≤ 0
`Spain`	FLOAT	Preço horário ES (€/MWh)	`0.00`	Validar e sinalizar valores ≤ 0

1.3.4 Meteorologia Horária

Fonte: Open-Meteo Historical API *Registos*: 8 783 (linhas de dados) *Período*: 2024-01-01 a 2024-12-31 *Coordenadas*: Lisboa

Tabela 1.5: Dicionário de dados — `open-meteo-38.70N9.20W64m.csv`.

Campo	Tipo Alvo	Descrição	Exemplo Real	Notas de Qualidade (Silver)
`time`	TIMESTAMP	Instante UTC horário	`2024-01-01T00:00`	Omitir 3 linhas iniciais de geolocalização
`temperature_2m`	FLOAT	Temperatura do ar a 2 m (°C)	`9.1`	Converter de texto para decimal
`cloud_cover`	FLOAT	Nebulosidade total (%)	`100`	Converter de texto para decimal
`shortwave_radiation`	FLOAT	Radiação solar global (W/m²)	`0.0`	Converter de texto para decimal
`precipitation`	FLOAT	Precipitação horária (mm)	`0.00`	Converter de texto para decimal

1.3.5 Energia Injetada por UPAC

Fonte: E-REDES Open Data *Registos*: 12 360 *Período*: 2023-05 a 2024-12 *Granularidade*: Mensal por distrito/concelho

Tabela 1.6: Dicionário de dados — `energia_injectada_upac.csv`.

Campo	Tipo Alvo	Descrição	Exemplo Real	Notas de Qualidade (Silver)
`data`	STRING	Período ano-mês	`2023-05`	Descartar colunas derivadas (`ano, mes`)
`ano_mes`	INTEGER	Chave temporal composta	`202305`	Manter como chave agregadora
`distrito, con_name`	STRING	Nomes administrativos	`Aguiar da Beira`	Resolver grafias inconsistentes
`codigo_distrito, ...`	STRING	Códigos (INE)	`0901`	Preservar formatos com zeros à esquerda
`nivel_tensao`	STRING	Nível de tensão	`BTN/BTE`	Utilizar como categoria
`potencia_instalada`	FLOAT	Potência instalada (kW)	`567.24`	Converter de texto para decimal
`numero_instalacoes`	INTEGER	Número de locais UPAC	`71`	Converter para inteiro
`energia`	FLOAT	Energia injetada (kWh)	`34771.338`	Converter de texto para decimal

1.3.6 Instalações Fotovoltaicas de Autoconsumo UPAC

Fonte: E-REDES Open Data *Registos*: 146 418 *Período*: Snapshot trimestral (2024T2) *Granularidade*: Freguesia / Tecnologia

Tabela 1.7: Dicionário de dados — `8-unidades-de-producao...csv`.

Campo	Tipo Alvo	Descrição	Exemplo Real	Notas de Qualidade (Silver)
`trimestre`	STRING	Período	`2024T2`	—
`distrito, concelho...`	STRING	Toponímia	`Coruche, Fajarda...`	Limpar e normalizar texto
`codigo_postal, cod...`	STRING	Códigos geográficos	`2100`	Preservar como chaves de junção
`tipo_tecnologia`	STRING	Tecnologia de origem	`Solar`	Categoria
`nivel_de_tensao`	STRING	Tensão da ligação	`MT`	Categoria
`escalao_potencia`	STRING	Escalão (kW)	`]30, 1000]`	Extrair limites via *Regex*
`numero_instalacoes`	INTEGER	Contagem de UPAC	`17`	Converter para inteiro
`potencia_instalada`	FLOAT	Potência total (kW)	`2669.05`	Converter de texto para decimal
`cpes, relacao_...`	FLOAT	Dados por contador	`0.2249`	Converter rácios para decimal

1.4 Integração e Relação entre Datasets

Os seis conjuntos de dados são integrados através da combinação `timestamp_utc` + `zona_geografica` (ou uma aproximação geográfica, no caso de meteorologia e UPAC). Esta integração permite:

- Relacionar, a cada hora, o preço MIBEL, a carga da rede e as condições meteorológicas;
- Derivar métricas de exposição financeira do comercializador;
- Construir variáveis de entrada para modelos de previsão de carga e produção solar;
- Explorar cenários de optimização doméstica de autoconsumo e venda de excedentes.

A integração entre dados horários (consumo, preço, meteorologia) e dados de granularidade inferior (mensal para UPAC, trimestral para inventário) requer estratégias de desagregação ou uso como variável contextual estática, a definir na camada *silver* do lakehouse.

1.5 Trabalho Futuro

Nas próximas fases do projeto, estes datasets serão:

- Ingeridos de forma automática para a camada *bronze* (via APIs e extração programática), com pipelines Flyte para fontes com API disponível;
- Limpos e alinhados temporalmente na camada *silver*, com aplicação de regras de qualidade (completude, unicidade, coerência temporal, validação de esquema);
- Agregados na camada *gold* em produtos de dados orientados a decisões: um índice de exposição ao preço de mercado, um modelo de previsão de carga a 24 h e um serviço de recomendação horária para prosumidores.

1.5.1 Fontes de Dados Complementares

Com base na análise exploratória dos datasets disponíveis, identificaram-se lacunas de cobertura temporal e temática que deverão ser colmatadas nas próximas fases do projeto, conforme a Tabela 1.8.

Tabela 1.8: Fontes de dados complementares recomendadas para trabalho futuro.

Fonte	**Dados**	**Justificação**	**Acesso**
Open-Meteo API (2023–2025)	Meteorologia horária (Temp., Rad., Neb.)	Ampliar cobertura temporal e geográfica do ficheiro atual (só 2024)	`archive-api.open-meteo.com`
E-REDES Open Data — produção	Produção nacional 15 min (2023–2025)	Ficheiro atual cobre apenas 2 meses	`e-redes.opendatasoft.com`
REN DataHub — Renováveis	Produção solar/eólica horária por tecnologia	Complementar visibilidade da geração distribuída	`datahub.ren.pt/en/electricity`
Calendário feriados PT	Feriados e dias especiais	Fator explicativo na previsão de carga	`date.nager.at/api/v3`

Bibliografia

[1] E-REDES. «Open Data Portal,» acedido em 12 de mar. de 2026. URL: https://e-redes.opendatasoft.com/

[2] REN. «REN DataHub - Electricity Market Data,» acedido em 12 de mar. de 2026. URL: https://datahub.ren.pt/en/electricity/market/

[3] Open-Meteo. «Historical Weather API,» acedido em 12 de mar. de 2026. URL: https://archive-api.open-meteo.com/v1/archive

[4] Nager.Date. «Public Holiday API,» acedido em 12 de mar. de 2026. URL: https://date.nager.at/api/v3